

## Bayesian Theorem 总结

Bayesian Theorem（贝叶斯定理）是一种概率推理方法，用于更新事件的概率，基于新的证据或信息。

- $P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$ 
  - $P(A|B)$ : 在事件 B 发生的条件下，事件 A 发生的后验概率（Posterior Probability）。
  - $P(B|A)$ : 在事件 A 发生的条件下，事件 B 发生的似然（Likelihood）。
  - $P(A)$ : 事件 A 的先验概率（Prior Probability）。
  - $P(B)$ : 事件 B 的边际概率（Marginal Probability）。

Bayesian Theorem 的核心思想是通过结合先验知识和新证据，动态调整对事件的概率估计。

### 条件概率（Conditional Probability）

条件概率是指在已知某一事件发生的条件下，另一个事件发生的概率。其公式为：

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

其中：

- $P(A|B)$ : 在事件 B 发生的条件下，事件 A 发生的概率。
- $P(A \cap B)$ : 事件 A 和事件 B 同时发生的概率。
- $P(B)$ : 事件 B 发生的概率。

条件概率是 Bayes' Theorem 的基础，用于描述事件之间的依赖关系。

---

### 联合概率

a、b 两个事件同时发生的概率，称为它们的**联合概率**，记作  $P(A \cap B)$  或  $P(A, B)$ 。

- 其定义为： $P(A \cap B)$  表示事件 A 和事件 B 同时发生的概率。
- 如果已知条件概率  $P(A|B)$  和  $P(B)$ ，则有： $P(A \cap B) = P(A|B) \cdot P(B)$
- 同理，也有： $P(A \cap B) = P(B|A) \cdot P(A)$

### 全概率公式（Law of Total Probability）

设  $B_1, B_2, \dots, B_n$  是一组两两不相交且覆盖全集的事件（即一个完备事件组），则对于任意事件 A，有：

- $P(A) = \sum_{i=1}^n P(A|B_i) \cdot P(B_i)$
- 全概率公式用于将事件 A 的概率分解为在不同条件  $B_i$  下的条件概率与  $B_i$  的概率的加权和。常用于贝叶斯推理和概率分布的分解。

---

## 朴素贝叶斯分类推理步骤及公式

### 1. 计算先验概率（Prior Probability）

每个类别  $C_k$  的先验概率： $P(C_k) = \frac{\text{类别 } C_k \text{ 的样本数}}{\text{总样本数}}$

## 2. 计算条件概率 (Likelihood)

对于每个特征  $x_i$ ，计算其在类别  $C_k$  下的条件概率：
$$P(x_i|C_k) = \frac{\text{类别 } C_k \text{ 中 } x_i \text{ 的样本数}}{\text{类别 } C_k \text{ 的样本数}}$$

## 3. 计算联合概率 (Naïve Bayes 假设条件独立)

假设各特征条件独立，联合概率为：
$$P(x_1, x_2, \dots, x_n|C_k) = \prod_{i=1}^n P(x_i|C_k)$$

## 4. 计算后验概率 (Posterior Probability)

对每个类别，利用贝叶斯公式计算后验概率：

- $$P(C_k|x_1, x_2, \dots, x_n) = \frac{P(x_1, x_2, \dots, x_n|C_k) \cdot P(C_k)}{P(x_1, x_2, \dots, x_n)}$$
- 由于分母对所有类别相同，实际分类时只需比较分子部分大小。

## 5. 分类决策

选择后验概率最大的类别作为预测结果：
$$\hat{C} = \arg \max_{C_k} [P(C_k) \prod_{i=1}^n P(x_i|C_k)]$$

## 6. 分类决策

比较后验概率，选择概率较大的类别作为预测结果。

# Bayesian Classification 总结

## 应用场景

- 文本分类:** 如垃圾邮件检测。
- 情感分析:** 基于文本内容预测情感类别。
- 医学诊断:** 基于症状预测疾病。

## 朴素贝叶斯分类的合理性

朴素贝叶斯分类的核心假设是特征之间的条件独立性，即在给定类别的条件下，每个特征对类别的贡献是独立的。优点是计算效率高，适用于高维数据，但其独立性假设在某些场景下可能不成立。

### 1. 简化计算

条件独立性假设将联合概率的计算从指数级复杂度简化为线性复杂度，使得朴素贝叶斯分类在高维数据中依然高效。

### 2. 鲁棒性

即使独立性假设不完全成立，朴素贝叶斯分类在许多实际场景中仍能提供良好的分类性能。这是因为它在概率估计中对误差具有一定的容忍度。

---

# Bayesian Belief Networks (BBN)

Bayesian Belief Networks (BBN) 是一种扩展的贝叶斯推理方法，用于显式捕获变量之间的依赖关系。它通过图形结构 (Directed Acyclic Graph, DAG) 和 Conditional Probability Tables (CPTs) 表示随机变量及其条件依赖性。

## 1. Directed Acyclic Graph (DAG)

- Nodes:** 表示随机变量。
- Edges:** 表示条件依赖性。

- 如果存在边  $A \rightarrow B$ ，则表示 B 条件依赖于 A。
- **注意:** DAG 是基于领域知识或数据分析构建的，用于表示变量之间的依赖关系，而不是直接从 CPT 表格中推导出来的。CPT 则用于量化这些依赖关系。

2. Conditional Probability Tables (CPTs)

CPT 示例及 BBN 使用方法

以下是一个简单的 CPT 示例，假设节点 A 的父节点为 B 和 C：

B	C	$P(A = 0/B, C)$	$P(A = 1/B, C)$
0	0	0.7	0.3
0	1	0.6	0.4
1	0	0.2	0.8
1	1	0.9	0.1

解释：

- 1. 每一行表示父节点 B 和 C 的一个可能组合。
- 2. 每一列表示目标节点 A 在该条件下的概率分布。例如：
  - 当  $B = 1$  且  $C = 0$  时：
    - $P(A = 0|B = 1, C = 0) = 0.2$
    - $P(A = 1|B = 1, C = 0) = 0.8$

BBN 步骤

1. 明确目标变量和已知变量

确定需要分类的目标变量（如 D）以及已知的条件变量（如 A, B, C）。

2. 构建依赖关系

根据 DAG 和 CPTs，明确目标变量与条件变量之间的依赖关系。例如：

- $P(D|A, B, C)$  表示在已知 A, B, C 的条件下，D 的后验概率。

3. 应用贝叶斯公式

使用贝叶斯公式计算后验概率：

◦ 
$$P(D|A, B, C) = \frac{P(A, B, C|D) \cdot P(D)}{P(A, B, C)}$$

4. 分解联合概率

根据 BBN 的依赖关系，分解联合概率。例如：

- 在 Naïve Bayes Classifier 中： $P(A, B, C|D) = P(A|D) \cdot P(B|D) \cdot P(C|D)$
- 在 BBN 中： $P(A, B, C|D) = P(A|D) \cdot P(B|A, D) \cdot P(C|A, B, D)$

5. 简化计算

根据条件独立性假设，进一步简化计算。例如：

- $P(A, B, C|D) = P(A|D) \cdot P(B) \cdot P(C|A, B)$

## 6. 计算后验概率

使用链式规则和 CPTs 计算后验概率。例如：

- $P(A_1, A_2, \dots, A_n) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1, A_2) \cdot \dots \cdot P(A_n|A_1, A_2, \dots, A_{n-1})$